МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
Кафедра компьютерных технологий и систем

Лабораторная работа № 3

Кононенко Даниил Александрович
3 курс, 4 группа

Минск – 2025

Содержание

1 Введение **2**

2 Загрузка и подготовка данных **2**
2.1 Источник и структура данных 2
2.2 Обработка пропущенных значений 2
2.3 Преобразование данных 2

3 Анализ данных **3**
3.1 Описание числовых признаков 3
3.2 Анализ категориальных признаков 3
3.3 Целевая переменная (Риск) 3

4 Визуальный анализ **3**
4.1 Матрица корреляций 3
4.2 Распределение данных (Гистограммы) 4
4.3 Анализ выбросов (Boxplots) 5

5 Работа с базой данных SQLite **6**
5.1 Пример 1: Выборка крупных кредитов 6
5.2 Пример 2: Агрегация по статусу риска 6
5.3 Пример 3: Группировка по типу работы 7

6 Итоговые выводы **7**

7 Заключение **7**

1 Введение

Цель работы: Проведение разведочного анализа данных (EDA) набора "German Credit Data"для выявления факторов, влияющих на кредитный риск, визуализация зависимостей и работа с данными посредством SQL-запросов.

Задачи:

- Загрузить и подготовить данные.
- Провести статистический анализ переменных.
- Визуализировать распределения и взаимосвязи признаков.
- Создать базу данных SQLite и выполнить аналитические запросы.

Инструменты: Язык Python, библиотеки: `pandas`, `numpy`, `matplotlib`, `seaborn`, `sqlite3`, `sklearn`.

2 Загрузка и подготовка данных

2.1 Источник и структура данных

Данные были загружены из локального файла `german.data` (исходный источник: UCI Machine Learning Repository). Файл не содержал заголовков, поэтому имена столбцов были назначены вручную согласно документации.

- **Количество наблюдений:** 1000 строк.
- **Количество признаков:** 21 (20 независимых переменных + 1 целевая).

2.2 Обработка пропущенных значений

В наборе данных отсутствуют пропущенные значения, поэтому удаление строк или импутация (заполнение) данных не потребовались.

2.3 Преобразование данных

1. Целевая переменная `class` (1 = Good, 2 = Bad) была преобразована в бинарный формат `target`:
   - 0 – надежный заемщик (Good);
   - 1 – рискованный заемщик (Bad).
2. Для категориальных признаков (таких как `checking_status`, `purpose`, `housing` и др.) было применено кодирование методом **Label Encoding** с использованием библиотеки `sklearn`.

3 Анализ данных

3.1 Описание числовых признаков

Основные статистики (mean, std, min, max) для ключевых числовых атрибутов:

- **Возраст (age):** Средний возраст заемщика – 35.5 лет. Диапазон от 19 до 75 лет.
- **Сумма кредита (credit_amount):** Средняя сумма – 3271 DM. Высокое стандартное отклонение (2822) указывает на большой разброс сумм. Максимальный кредит – 18424 DM.
- **Длительность (duration):** В среднем 20.9 месяцев, максимум – 72 месяца (6 лет).

3.2 Анализ категориальных признаков

Анализ частот показал:

- **Checking status:** Самая частая категория – "A14"(нет расчетного счета), 394 записи.
- **Employment:** Большинство заемщиков имеют стаж работы (A73 – 1-4 года, A75 – более 7 лет).
- **Housing:** 713 человек (71.3%) имеют собственное жилье (категория A152).
- **Foreign worker:** 963 человека (96.3%) являются иностранными работниками.

3.3 Целевая переменная (Риск)

Распределение классов:

- 700 (70%) – надежные заемщики (Target 0).
- 300 (30%) – ненадежные заемщики (Target 1).

Наблюдается дисбаланс классов, что типично для задач кредитного скоринга.

4 Визуальный анализ

4.1 Матрица корреляций

Была построена тепловая карта (Heatmap) для числовых признаков.

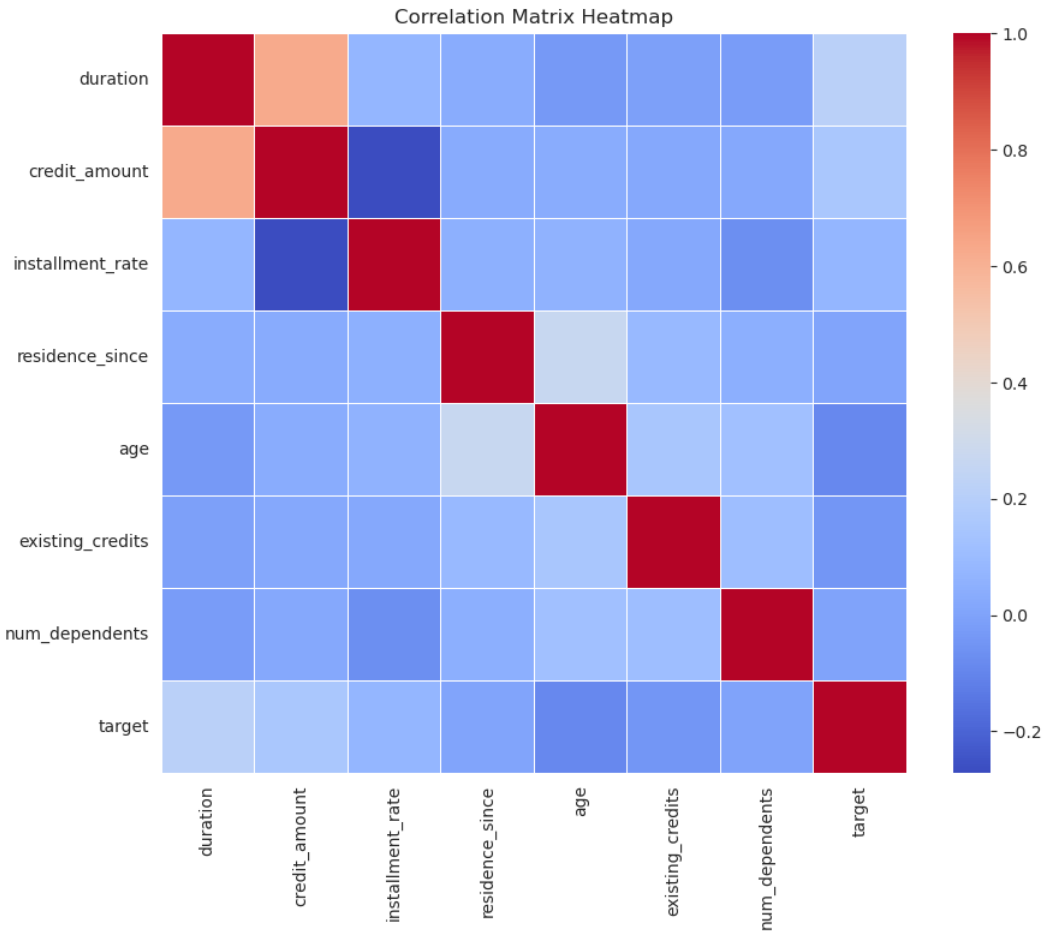


Рис. 1: Матрица корреляций числовых признаков

Интерпретация:

- Наблюдается заметная положительная корреляция между `credit_amount` и `duration` (0.62). Это логично: большие суммы берутся на более длительный срок.
- Корреляция между остальными признаками слабая.

4.2 Распределение данных (Гистограммы)

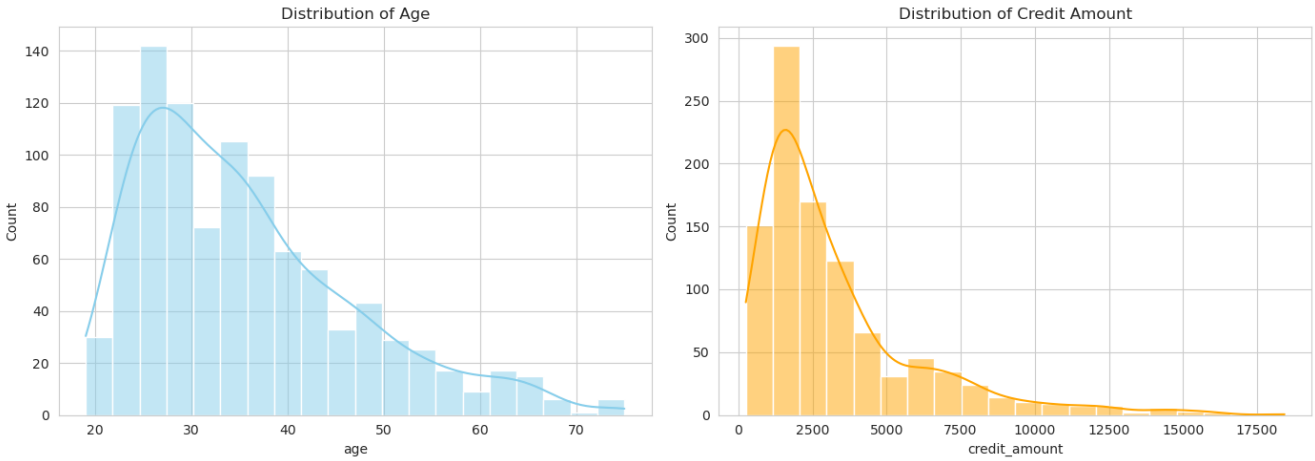


Рис. 2: Распределение возраста и суммы кредита

Интерпретация:

- **Возраст:** Распределение смещено вправо (Right-skewed). Основная масса заемщиков – люди от 25 до 40 лет.
- **Сумма кредита:** Сильно смещено вправо. Большинство кредитов – небольшие (до 5000 DM), но есть "длинный хвост"крупных займов.

4.3 Анализ выбросов (Boxplots)

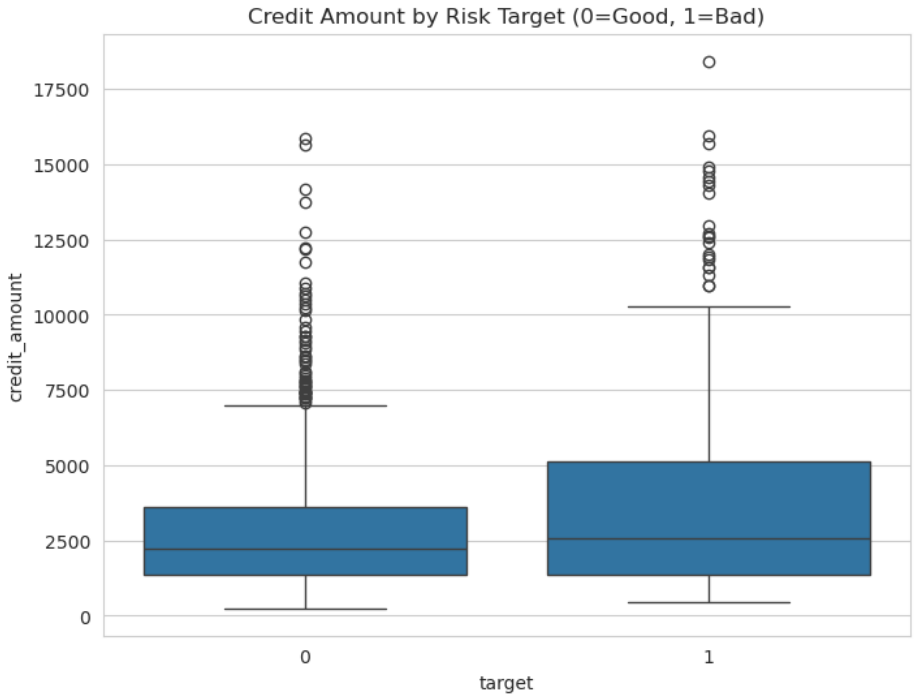


Рис. 3: Связь суммы кредита и риска (0 - Good, 1 - Bad)

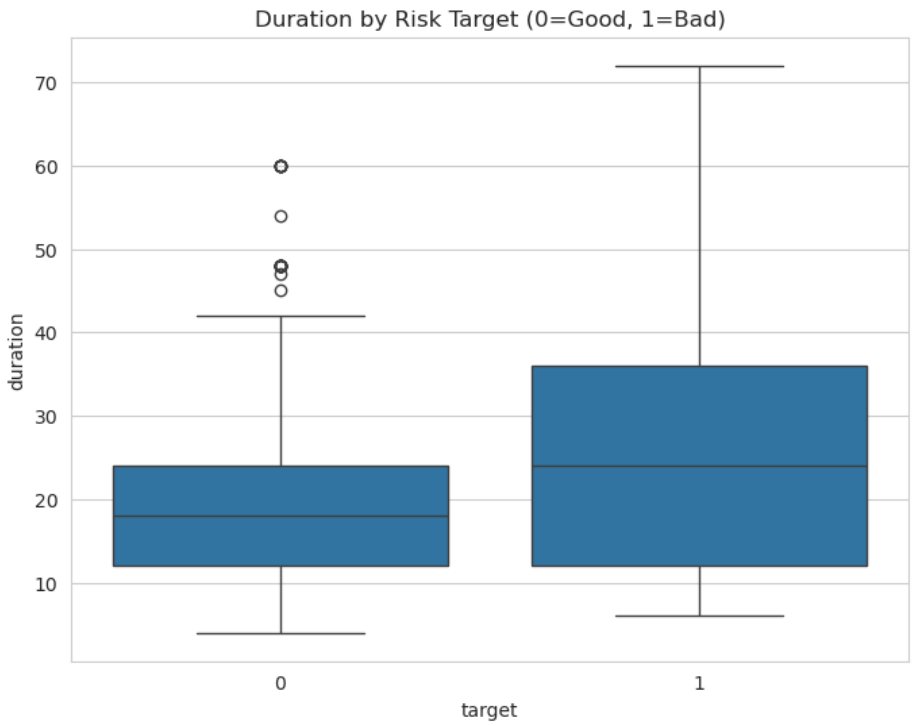


Рис. 4: Связь длительности кредита и риска (0 - Good, 1 - Bad)

Интерпретация:

- **Сумма кредита:** Медианное значение суммы кредита выше для рискованных заемщиков (Target 1). Разброс значений также больше.
- **Длительность:** Рискованные кредиты в среднем имеют большую длительность, чем надежные. Это важный инсайт: *долгосрочные кредиты чаще оказываются проблемными.*

5 Работа с базой данных SQLite

Была создана локальная база данных `german_credit.db` и таблица `credits`. Данные из DataFrame были успешно экспортированы в SQL.

5.1 Пример 1: Выборка крупных кредитов

Запрос на получение первых 5 записей с суммой кредита более 10000 DM:

```
SELECT age, credit_amount, duration, target
FROM credits
WHERE credit_amount > 10000
LIMIT 5
```

Результат: Найдены записи, где суммы достигают 14-15 тыс., и во всех 5 случайных примерах статус риска = 1 (Bad).

5.2 Пример 2: Агрегация по статусу риска

Сравнение средних сумм кредита для надежных и ненадежных клиентов.

```sql
SELECT target, AVG(credit_amount) as avg_credit, COUNT(*) as count
FROM credits
GROUP BY target
```

Результат:

- Target 0 (Good): Средний кредит ≈ 2985 DM (700 человек).
- Target 1 (Bad): Средний кредит ≈ 3938 DM (300 человек).

SQL-запрос подтвердил вывод визуального анализа: проблемные кредиты в среднем на 1000 DM больше.

5.3 Пример 3: Группировка по типу работы

Поиск максимального и минимального кредита для каждой категории занятости (`job`).

```sql
SELECT job, MAX(credit_amount) as max_credit, MIN(credit_amount) as min_credit
FROM credits
GROUP BY job
```

Результат: Категория Job=3 (высококвалифицированные/руководство) имеет самый высокий потолок кредита (18424 DM).

6 Итоговые выводы

По результатам лабораторной работы можно сделать следующие заключения:

1. **Значимые признаки:** Наиболее информативными признаками для определения риска оказались **сумма кредита (Credit Amount)** и **длительность кредита (Duration)**.
2. **Взаимосвязи:**
   - Обнаружена прямая корреляция между суммой и сроком кредита.
   - Выявлена зависимость риска от параметров кредита: "плохие"кредиты в среднем выше по сумме (3938 против 2985) и длиннее по сроку (25 месяцев против 19), чем "хорошие".
3. **Рекомендации:** При скоринге особое внимание следует уделять заявкам на крупные суммы с длительным сроком погашения, так как статистика показывает повышенную вероятность дефолта в этом сегменте.
4. **Техническая часть:** Данные успешно загружены, очищены, визуализированы с помощью Python и сохранены в базу данных SQLite для дальнейшего использования.

7 Заключение

В ходе лабораторной работы были закреплены навыки использования библиотек `pandas`, `matplotlib`, `seaborn` и `sqlite3`. Проведен полный цикл анализа данных: от загрузки "сырого"файла без заголовков до формирования бизнес-выводов на основе статистики и SQL-запросов.